

دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

تمرین سری سه

درس بهینه‌سازی

فرهاد دلیرانی

۹۶۱۳۱۱۲۵

dalirani@aut.ac.ir

dalirani.1373@gmail.com

فهرست

ابزارهای استفاده شده ۱

تمرین ۱ ۲

تمرین ۲ ۴

تمرین ۳ ۵

تمرین ۴ ۸

تمرین ۵ ۱۰

تمرین ۶ ۱۱

ابزارهای استفاده شده

زبان برنامه نویسی: -

محیط توسعه: -

سیستم عامل: -

$$(1) \quad \begin{cases} Ax = b & (1) \\ Ay = r_0 & (2) \end{cases} \quad \text{راساس الگوریتم گاردیان مزدوج، برای دو مسئله}$$

$$x_k = y_k + x_0 \quad \text{در تمام گام ها} \quad r_{(1)k} = r_{(2)k} \quad \text{است همین طور}$$

۱۶

۱۷

۱۸

۱۹

۲۰

۲۱

۲۲

۲۳

۲۴

$$r_{(1)0} = Ax_0 - b$$

در قدم ۰

$$r_{(2)0} = Ay_0 - r_0 = 0 - r_0 = -(b - Ax_0) = Ax_0 - b$$

$$p_{(1)0} = -r_{(1)0} = b - Ax_0$$

$$p_{(2)0} = -r_{(2)0} = b - Ax_0$$

$$\begin{matrix} r_{(1)0} = r_{(2)0} \\ p_{(1)0} = p_{(2)0} \end{matrix} \rightarrow \alpha_{(1)0} = \alpha_{(2)0}$$

$$x_1 = x_0 + \alpha_{(1)0} p_{(1)0}$$

$$y_1 = y_0 + \alpha_{(2)0} p_{(2)0}$$

$$\rightarrow y_1 - x_1 = -x_0 \rightarrow x_1 = y_1 + x_0$$

$$r_{(1)1} = Ax_1 - b$$

$$r_{(2)1} = Ay_1 - r_0$$

$$\rightarrow r_{(1)1} - r_{(2)1} = Ax_1 - b - Ay_1 + r_0$$

$$= Ax_0 + r_0 - b$$

$$= Ax_0 + b - Ax_0 - b = 0$$

$$\rightarrow \boxed{r_{(1)1} = r_{(2)1}}$$

$$p_{(1)0} = p_{(2)0} \rightarrow \boxed{p_{(1)1} = p_{(2)1}}$$

در پایان قدم هر مشاهده کردیم که P_1 و r_1 برای هر دو معادله یکسان

است. در ابتدا $X_0 = Y_0 + \lambda_0$ برقرار بود بعد از پایان قدم

مشاهده شد که $X_1 = Y_1 + \lambda_0$ برقرار است.

اگر قدم های بعدی را مانند آن چه که در قدم هر انجام داریم دوباره انجام دهیم

به نتیجه گیری یکسانی می رسم و مشاهده می کنیم که در هر قدم P_k و r_k

برای هر دو معادله یکسانی شود و رابطی زیر بین X_k و Y_k برقرار

است:

$$X_k = Y_k + \lambda_0$$

در نتیجه در روش گرادینت مزدوج که برای سیستم $Ax=b$ شروع از

نقطه x_0 معادل شروع از نقطه $y_0=0$ برای سیستم $Ay=r_0$

است. که در آن $r_0 = b - Ax_0$.

(۲) برای این کار ~~عبارت~~ عبارت $\frac{1}{N} \sum_{i=1}^N (d_i - d(x_i, y_i))^2$

را کمینه می‌کنیم. هر چه MSE کمتر شود نشان ~~دهنده~~ این

است که به تخمین بهتری رسیده‌ایم.

در نتیجه برای پیدا کردن P مسئله‌ی زیر را حل می‌کنیم

minimize $\frac{1}{N} \sum_{i=1}^N (d_i - d(x_i, y_i))^2$
 P در درون این تابع است.

این یک مسئله‌ی Convex است، زیرا

$$\frac{1}{N} \sum_{i=1}^N (d_i - d(x_i, y_i))^2 = \frac{1}{N} \sum_{i=1}^N [d_i^2 - 2d_i d(x_i, y_i) + d^2(x_i, y_i)]$$

$$= \frac{1}{N} \sum_{i=1}^N \left[\underbrace{d_i^2}_{\text{Constant}} - \underbrace{2d_i ((x_i - y_i)^T P (x_i - y_i))^{\frac{1}{2}}}_{\text{ترکیب یک تابع خطی بر حسب } P \text{ با یک تابع مقعر (جذر) یک تابع مقعر است که ضرب یک عدد منفی در آن موجب ~~موجب~~ محدب شدن آن می‌شود}} + \underbrace{(x_i - y_i)^T P (x_i - y_i)}_{\text{یک تابع خطی بر حسب } P \text{ است.}}$$

Constant
 مجموع جمع چند تابع
 محدب با ضرایب
 مثبت تابعی
 محدب است.

ترکیب ~~یک~~ یک تابع خطی
 بر حسب P با یک تابع
 مقعر (جذر) یک تابع مقعر است
 که ضرب یک عدد منفی در
 آن موجب ~~موجب~~
 محدب شدن آن می‌شود.

یک تابع خطی
 بر حسب P
 است.

در نتیجه کل عبارت Convex است.

y is a random variable. $y \in \{0, 1\}$ (۲)

$$y = \begin{cases} 1 & a^T u + b + v \leq 0 \\ 0 & a^T u + b + v > 0 \end{cases}$$

u : $u \in \mathbb{R}^n$ is a ~~vector~~ ~~vector~~ vector of explanatory

v : v is a zero mean unit variance gaussian variable. $N(0, 1)$

Integral in Normal Gaussian Distribution: $F(x) = \int_x^\infty \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx$

$$P(y=1) = P(a^T u + b + v \leq 0) = P(a^T u - b \geq v) =$$

$$= \int_{-\infty}^{-a^T u - b} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx \stackrel{\text{even function}}{=} \int_{a^T u + b}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = F(a^T u + b)$$

$$P(y=0) = P(a^T u + b + v > 0) = P(-a^T u - b < v) =$$

$$= \int_{-a^T u - b}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = F(-a^T u - b)$$

Log-Likelihood:

$$L(a, b) = \sum_{y_i=1} \log F(a^T u_i + b) + \sum_{y_i=0} \log F(-a^T u_i - b)$$

ادامه ۳ تابع یک $\frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$

تابع \log -concave است. یعنی در رابطه

زیر صدق می کند

$$f(\theta x + (1-\theta)y) \geq f(x)^\theta f(y)^{1-\theta}$$

$$e^{-\frac{(\theta x + (1-\theta)y)^2}{2}} \geq \left(e^{-\frac{x^2}{2}}\right)^\theta \left(e^{-\frac{y^2}{2}}\right)^{1-\theta}$$

$$e^{-\frac{(\theta x + (1-\theta)y)^2}{2}} \geq \left(e^{-\frac{x^2}{2}}\right)^\theta \left(e^{-\frac{y^2}{2}}\right)^{1-\theta}$$

$$-(\theta x + (1-\theta)y)^2 \geq -\theta x^2 - (1-\theta)y^2$$

$$(\theta x + (1-\theta)y)^2 \leq \theta x^2 + (1-\theta)y^2$$

$$\theta^2 x^2 + (1-\theta)^2 y^2 + 2\theta(1-\theta)xy - \theta x^2 - (1-\theta)y^2 \leq 0$$

$$(\theta^2 - \theta)x^2 + ((1-\theta)^2 - (1-\theta))y^2 + 2\theta(1-\theta)xy \leq 0$$

$$\theta(\theta-1)x^2 + (1-\theta)((1-\theta)-1)y^2 + 2\theta(1-\theta)xy \leq 0$$

$$+\theta(\theta-1)x^2 + (1-\theta)(-\theta)y^2 + (2\theta)(1-\theta)xy \leq 0$$

$$(-\theta)x^2 + (-\theta)y^2 + (2\theta)xy \leq 0$$

$$-x^2 - y^2 + 2xy \leq 0 \iff -(x-y)^2 \leq 0 \quad \checkmark$$

نشان داده شد که $\frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$ یک تابع \log -concave است. قواعد

\log -concave تحت marginalization خاصیت خود را حفظ می کنند. در نتیجه

$$F(x) = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx$$

یک تابع \log -concave است. اگر \dots تابع

\log -concave با ترکیب شوند \dots حاصل \log -concave خواهند بود در نتیجه

$\log F(x)$ یک تابع concave است

ادامی (۳)

در نتیجه ترکیب affine تابع $\log F(a)$ هم یک تابع

concave است. پس $\log F(a^T u_i + b)$ و $\log F(-a^T u_i - b)$

هر دو concave هستند و در نهایت نتیجه می شود که تابع

$L(a, b)$ یک تابع concave است.

در نتیجه داریم maximum $L(a, b)$

یا

minium $-L(a, b)$

$$\text{minimize } \sum_{i=1}^m \phi(r_i)$$

$$\text{S.T. } r = Ax - b$$

$$L(r, x, \nu) = \sum_{i=1}^m \phi(r_i) + \nu^T (Ax - b - r)$$

$$g(\nu) = \inf_r \left(\sum_{i=1}^m \phi(r_i) + \nu^T Ax - \nu^T b - \nu^T r \right)$$

$$= \inf_r \left(\sum_{i=1}^m \phi(r_i) - \nu^T r \right) - \nu^T b$$

برای جلوگیری از $-\infty$ شدن

$g(\nu)$ باید ضریب x

برابر با ~~صفر~~ صفر باشد.

روز مباحثه پیامبر اسلام صلی الله علیه و آله (۱۰ هـ ق)

۱۷

۲۵ ذی الحجه ۱۴۳۶

9 October 2015

جمعه مهر

$$= - \sup_r \left(\nu^T r - \sum_{i=1}^m \phi(r_i) \right) - \nu^T b$$

$$g(\nu) = - f_0^*(\nu) - \nu^T b$$

$$g(\nu) = \begin{cases} -f_0^*(\nu) - \nu^T b & \nu^T A = 0 \\ -\infty & \text{Else} \end{cases}$$


$$\begin{aligned} &\text{maximize } g(\nu) = -f_0^*(\nu) - \nu^T b \\ &\text{subject to: } \nu^T A = 0 \end{aligned}$$

$$f_0(r) = \sum_{i=1}^m \phi(r_i) = \sum_{i=1}^m \max(0, |r_i| - 1)$$

$$f_0^*(v) = \sup_r (v^T r - \sum_{i=1}^m \phi(r_i))$$

$$= \sup_r \left(\sum_{i=1}^m [v_i r_i - \phi(r_i)] \right) =$$

$$= \sup_r \left(\sum_{i=1}^m [v_i r_i - \max(0, |r_i| - 1)] \right)$$



$$f^*(v) = \begin{cases} +\infty & \|v\|_\infty > 1 \\ \|v\|_1 & \|v\|_\infty \leq 1 \end{cases}$$

$$\rightarrow g(v) = \begin{cases} -\|v\|_1 - v^T b & \|v\|_\infty \leq 1 \text{ and } v^T A = d \\ -\infty & \text{Else} \end{cases}$$

$$\begin{aligned} \text{maximum } & g(v) = -\|v\|_1 - v^T b \\ \text{Subject to } & \|v\|_\infty \leq 1 \\ & v^T A = d \end{aligned}$$

(5)

$$\min \quad 0.5 \|y - y_0\|_2 + \sum_{i=1}^m \|x_i\|_2$$

$$\text{s.t.} \quad x_i = c_i y + d_i$$

$$L(x, y, \nu) = 0.5 \|y - y_0\|_2 + \sum_{i=1}^m \|x_i\|_2 + \sum_{i=1}^m \nu_i^T (x_i - c_i y - d_i)$$

$$\rightarrow L(x, y, \nu) = 0.5 \|y - y_0\|_2 + \sum_{i=1}^m \nu_i^T (-c_i y) + \sum_{i=1}^m \|x_i\|_2 + \sum_{i=1}^m \nu_i^T x_i + \sum_{i=1}^m \nu_i^T (-d_i)$$

$$\rightarrow L(x, y, \nu) = - \sum_{i=1}^m \nu_i^T c_i y + 0.5 \|y - y_0\|_2 + \sum_{i=1}^m (\|x_i\|_2 + \nu_i^T x_i) - \sum_{i=1}^m \nu_i^T d_i$$

$$\rightarrow L(x, y, \nu) = - \left[\sum_{i=1}^m \nu_i^T c_i y - 0.5 \|y - y_0\|_2 \right] + \sum_{i=1}^m [\|x_i\|_2 + \nu_i^T x_i] - \sum_{i=1}^m \nu_i^T d_i$$

$$\rightarrow L(x, y, \nu) = - \left[\sum_{i=1}^m \nu_i^T c_i y - 0.5 \|y - y_0\|_2 \right] - \sum_{i=1}^m [-\nu_i^T x_i - \|x_i\|_2] - \sum_{i=1}^m \nu_i^T d_i$$

$$g(\nu) = \inf_y \left[\sum_{i=1}^m \nu_i^T c_i y - 0.5 \|y - y_0\|_2 \right] + \inf_x \left[- \sum_{i=1}^m [-\nu_i^T x_i - \|x_i\|_2] \right] - \sum_{i=1}^m \nu_i^T d_i$$

$$g(\nu) = \sup_y \left[\sum_{i=1}^m (\nu_i^T c_i y - 0.5 \|y - y_0\|_2) \right] + \sup_x \sum_{i=1}^m [-\nu_i^T x_i - \|x_i\|_2] - \sum_{i=1}^m \nu_i^T d_i$$

$$f_1(y) = \frac{0.5}{m} \|y - y_0\|_2$$

$$f_2(x_i) = \|x_i\|_2$$

$$\Rightarrow g(\nu) = \sum_{i=1}^m f_1^*(\nu_i^T c_i) + \sum_{i=1}^m f_2^*(-\nu_i) - \sum_{i=1}^m \nu_i^T d_i$$

$$\rightarrow g(\nu) = \sum_{i=1}^m f_1^*(c_i^T \nu_i) + \sum_{i=1}^m f_2^*(-\nu_i) - \sum_{i=1}^m \nu_i^T d_i$$

$$g(\nu) = \begin{cases} - \sum_{i=1}^m (\nu_i^T d_i - y_0^T c_i^T \nu_i) & \|c_i^T \nu\|_2 \leq 1 \text{ and } \|\nu_i\| \leq 1 \\ \infty & \text{Else} \end{cases}$$

$$\text{minimize } f_0(x)$$

$$\text{s.t. } Ax=b$$

$$L(x, \nu) = f_0(x) + \nu^T (Ax - b)$$

$$g(\nu) = \inf_x L(x, \nu) \rightarrow$$

$$g(\nu) = \inf_x (f_0(x) + \nu^T (Ax - b))$$

$$p(x) = f(x) + \alpha \|Ax - b\|_2^2 = f(x) + \alpha (Ax - b)^T (Ax - b)$$

$$\rightarrow p(x) = f(x) + \alpha (x^T A^T - b^T) (Ax - b)$$

$$= f(x) + \alpha (x^T A^T A x - x^T A^T b - b^T A x + b^T b)$$

$$\rightarrow 0 = \nabla f_0(x^*) + \alpha (2A^T A x^* - 2A^T b)$$

$$\rightarrow 0 = \nabla f_0(x^*) + 2\alpha A^T (Ax^* - b)$$

در صورتی که ν را برابر با $2\alpha(Ax^* - b)$ مقرر بگیریم آنگاه x^* تابع
زیر را کمینه می کند

$$f_0(x) + \nu^T (Ax - b)$$

که ν یک dual مسئله دارد شده است
visible

$$g(\nu) = \inf_x (f_0(x) + \nu^T (Ax - b)) = f_0(x^*) + 2\alpha \|Ax^* - b\|_2^2$$

بنابراین حود پایین برابری شود با

$$f_0(x^*) + 2\alpha \|Ax^* - b\|_2^2 \leq f_0(x)$$

when $Ax=b$